

Санкт-Петербургский государственный университет

Направление "Большие данные и распределенная цифровая платформа"

Лабораторная работа по дисциплине

Алгоритмы и структуры данных

"Кластеризация данных."

Выполнил:

Зайнуллин Мансур Альбертович

Группа: 23.Б16-пу

Руководитель:

Дик Александр Геннадьевич

ассистент кафедры компьютерного
моделирования

и многопоточных систем

Санкт-Петербург

2025

Оглавление

1	Цель работы	3
2	Теоретические основы	4
2.1	Односвязывающий метод кластеризации	4
2.2	Алгоритм случайного поиска с адаптацией (СПА)	4
2.3	Расстояние Чебышева	5
2.4	Индекс Фоулкса-Мэллова	5
3	Описание программы	6
3.1	Структура проекта	6
3.2	Спецификация программы	7
3.2.1	Модуль data_preprocessing.py	7
3.2.2	Модуль mathematical_algorithms.py	9
3.2.3	Модуль clustering_gui.py	10
4	Набор данных	11
5	Контрольный пример	12
6	Рекомендации пользователю	18
6.1	Установка и запуск	18
6.2	Использование программы	18
6.2.1	Этап 1: Подготовка данных	18
6.2.2	Этап 2: Анализ признаков	18
6.2.3	Этап 3: Кластеризация	19
6.2.4	Этап 4: Анализ результатов	19
6.3	Интерпретация результатов	19
7	Проведение эксперимента	20
7.1	Методология исследования	20
7.2	Результаты тестирования	21
7.2.1	Выбор информативных признаков	21
7.2.2	Результаты кластеризации	22

7.2.3	Результаты сравнения методов	25
7.2.4	Количественные характеристики	26
7.3	Анализ результатов	27
7.3.1	Эффект цепочки в односвязывающем методе	27
7.3.2	Влияние отбора признаков	27
7.3.3	Влияние анонимизации	28
7.3.4	Сравнение с K-means	28
8	Выводы	29
9	Полезные ссылки	30

1 Цель работы

Исследовать эффективность односвязывающего метода кластеризации на данных студенческого поведения с использованием расстояния Чебышева в качестве метрики. Применить алгоритм случайного поиска с адаптацией (СПА) для выбора наиболее информативных признаков. Оценить влияние предобработки данных и анонимизации на качество кластеризации с помощью индекса Фоулкса-Мэллова.

2 Теоретические основы

2.1 Односвязывающий метод кластеризации

Односвязывающий метод — иерархический алгоритм кластеризации. Расстояние между кластерами определяется как минимальное расстояние между любыми двумя точками из разных кластеров:

$$d(C_i, C_j) = \min d(x, y) : x \in C_i, y \in C_j$$

Алгоритм:

1. Каждый объект — отдельный кластер
2. На каждом шаге объединяются два ближайших кластера
3. Процесс повторяется до получения заданного количества кластеров

Временная сложность: $O(n^3)$.

2.2 Алгоритм случайного поиска с адаптацией (СПА)

СПА выбирает оптимальное подмножество признаков, адаптивно изменяя вероятности их выбора на основе качества результата.

Каждому признаку x_i сопоставляется вероятность выбора $p_i(t)$, которая обновляется по формуле:

$$p_i(t+1) = p_i(t) + \alpha \cdot \frac{\Delta Q(t)}{\sigma_Q(t)} \cdot I_i(t)$$

где $\Delta Q(t)$ — отклонение качества от среднего, $I_i(t)$ — индикатор включения признака.

Алгоритм: итеративно выбирает признаки согласно текущим вероятностям, оценивает качество и адаптирует вероятности.

2.3 Расстояние Чебышева

Расстояние Чебышева определяется как максимальная координатная разность:

$$d_{\text{Chebyshev}}(x, y) = \max_{i=1, \dots, n} |x_i - y_i|$$

Геометрически: окружность в метрике Чебышева представляет собой квадрат.

2.4 Индекс Фоулкса-Мэллова

Индекс Фоулкса-Мэллова оценивает качество кластеризации через сравнение с истинным разбиением:

$$FM = \sqrt{\text{Precision} \times \text{Recall}} = \sqrt{\frac{TP}{TP + FP} \times \frac{TP}{TP + FN}}$$

где TP — количество пар объектов, правильно отнесенных к одному кластеру.

Диапазон значений: $[0, 1]$, где 1 соответствует полному совпадению разбиений.

3 Описание программы

3.1 Структура проекта

- `data_preprocessing.py`: Предобработка данных, выбор признаков алгоритмом СПА, анонимизация
- `mathematical_algorithms.py`: Реализация односвязывающего метода, СПА, расстояния Чебышева и индекса Фоулкса-Мэллова
- `clustering_gui.py`: Графический интерфейс с визуализацией результатов кластеризации
- `student_habits_performance.csv`: Датасет с данными о 99 студентах (16 признаков)

Основные классы:

- `StudentDataProcessor` — управление данными и кластеризацией
- `FeatureSelector` — выбор информативных признаков

Поток выполнения: загрузка данных → предобработка → выбор признаков → кластеризация → анонимизация → повторная кластеризация → сравнение результатов.

3.2 Спецификация программы

3.2.1 Модуль data_preprocessing.py

Класс StudentDataProcessor

Table 1: Методы класса StudentDataProcessor

Метод/Атрибут	Описание	Входные/Выходные данные
<code>__init__(data_filepath, cache_dir)</code>	Инициализация	<code>data_filepath</code> (str), <code>cache_dir</code> (str) → <code>StudentDataProcessor</code>
<code>load_and_analyze_data(force_reload)</code>	Загрузка и анализ исходных данных	<code>force_reload</code> (bool) → <code>Dict[str, Any]</code>
<code>preprocess_data(config, use_cache)</code>	Предобработка данных согласно конфигурации	<code>config</code> (<code>PreprocessingConfig</code>), <code>use_cache</code> (bool) → <code>pd.DataFrame</code>
<code>select_informative_features(clustering_method, n_clusters, distance_metric)</code>	Выбор наиболее информативных признаков с использованием СПА	<code>n_features</code> (int), <code>clustering_method</code> (str), <code>n_clusters</code> (int), <code>distance_metric</code> (str) → <code>List[str]</code>
<code>analyze_k_anonymity(quasi_identifiers, use_processed_data)</code>	Анализ k-анонимности данных	<code>quasi_identifiers</code> (<code>List[str]</code>), <code>use_processed_data</code> (bool) → <code>Dict[str, Any]</code>

Класс FeatureSelector

Table 2: Методы класса FeatureSelector

Метод/Атрибут	Описание	Входные/Выходные данные
<code>__init__(random_state)</code>	Инициализация селектора признаков с интеграцией СПА	<code>random_state (int) → FeatureSelector</code>
<code>select_features_spa(data, n_features, clustering_method, n_clusters, distance_metric, max_iterations)</code>	Выбор признаков с использованием алгоритма СПА	<code>data (pd.DataFrame), n_features (int), clustering_method (str), n_clusters (int), distance_metric (str), max_iterations (int) → Tuple[List[str], float]</code>

3.2.2 Модуль `mathematical_algorithms.py`

Table 3: Функции модуля `mathematical_algorithms.py`

Объект/Функция	Описание	Входные/Выходные данные
<code>euclidean_distance(x, y)</code>	Вычисление евклидова расстояния с повышенной численной стабильностью	<code>x</code> (<code>np.ndarray</code>), <code>y</code> (<code>np.ndarray</code>) → <code>float</code>
<code>chebyshev_distance(x, y)</code>	Вычисление расстояния Чебышева с обработкой граничных случаев	<code>x</code> (<code>np.ndarray</code>), <code>y</code> (<code>np.ndarray</code>) → <code>float</code>
<code>single_linkage_clustering(data, n_clusters, metric, return_hierarchy, verbose)</code>	Робастная реализация односвязывающего метода с комплексной защитой от ошибок	<code>data</code> (<code>np.ndarray</code>), <code>n_clusters</code> (<code>int</code>), <code>metric</code> (<code>str</code>), <code>return_hierarchy</code> (<code>bool</code>), <code>verbose</code> (<code>bool</code>) → <code>Union[<code>np.ndarray</code>, <code>Tuple[<code>np.ndarray</code>, <code>List</code>]</code>]</code>
<code>spa_feature_selection(data, n_features, quality_function, max_iterations, learning_rate, random_state, verbose)</code>	Численно стабильная реализация алгоритма СПА с улучшенной сходимостью	<code>data</code> (<code>np.ndarray</code>), <code>n_features</code> (<code>int</code>), <code>quality_function</code> (<code>callable</code>), <code>max_iterations</code> (<code>int</code>), <code>learning_rate</code> (<code>float</code>), <code>random_state</code> (<code>int</code>), <code>verbose</code> (<code>bool</code>) → <code>Tuple[<code>List[<code>int</code>]</code>, <code>float</code>, <code>List[<code>dict</code>]</code>]</code>
<code>fowlkes_mallows_index(true_labels, pred_labels)</code>	Численно стабильное вычисление индекса Фоулкса-Мэллова	<code>true_labels</code> (<code>np.ndarray</code>), <code>pred_labels</code> (<code>np.ndarray</code>) → <code>float</code>

3.2.3 Модуль clustering_gui.py

Класс EnhancedClusteringApp

Table 4: Методы класса EnhancedClusteringApp

Метод/Атрибут	Описание	Входные/Выходные данные
<code>__init__(root)</code>	Инициализация приложения для кластеризации с разделенным функционалом	<code>root (tk.Tk)</code> → <code>EnhancedClusteringApp</code>
<code>_load_data()</code>	Загрузка данных с обновленной логикой	— → Обновление состояния данных
<code>_preprocess_data()</code>	Предобработка данных	— → Обновление <code>processed_data</code>
<code>_run_spa_analysis()</code>	Запуск СПА анализа без применения результатов к датасету	— → Обновление <code>spa_analysis_results</code>
<code>_perform_clustering()</code>	Метод кластеризации с улучшенными проверками	— → Обновление <code>cluster_labels</code> и визуализации
<code>_analyze_k_anonymity()</code>	Анализ К-анонимности	— → Обновление <code>k_anonymity_results</code>
<code>_anonymize_and_compare()</code>	Метод анонимизации и сравнения	— → Обновление <code>clustering_comparison_res</code>

4 Набор данных

Используется синтетический датасет “**Student Habits vs Academic Performance**” с платформы Kaggle. Содержит 1000 записей студентов с 16 признаками, характеризующими образ жизни и академическую успеваемость.

Структура данных:

- **Числовые (9):** возраст, часы учебы/сна, время в соцсетях/Netflix, посещаемость, физическая активность, ментальное здоровье, оценка за экзамен
- **Категориальные (5):** пол, качество питания/интернета, образование родителей
- **Бинарные (2):** подработка, внеучебная деятельность
- **Идентификатор (1):** ID студента

Отсутствуют пропущенные значения.

5 Контрольный пример




Рис 1. Выполнили: запустили интерфейс -> "Загрузить данные" -> "Предобработать" -> выбрали алгоритм кластеризации "kmeans"




Рис 2. Запустили СПА. Правая панель содержит результаты отбора признаков.




Рис 3. Кластеризовали по всему предобработанному набору данных.




Рис 4. Интерфейс выбора 3-х осей для вывода визуализации кластеризации, сделанной в предыдущем пункте




Рис 5. Визуализации кластеризации по осям social-media-hours, sleep-hours, exam-score




Рис 6. Другой ракурс визуализации кластеризации по осям social-media-hours, sleep-hours, exam-score




Рис 7. Выберем другие 3 оси для визуализации кластеризации




Рис 8. Кластеризации на всём датасете с визуализацией по осям: study-hours-per-day, age, mental-health-rating




Рис 9. Другой ракурс визуализации на всём датасете с визуализацией по осям: study-hours-per-day, age, mental-health-rating




Рис 10. Другой ракурс визуализации с фокусировкой на осях study-hours-per-day и mental-health-rating

Результаты кластеризации методом K-means (K=3):

Алгоритм K-means выявил три различных академических профиля студентов:

Кластер 1 (жёлтые) — *«Высокоэффективная стрессовая группа»*: студенты с высокими академическими результатами и значительными временными затратами на учёбу, но страдающие от низкого уровня ментального здоровья.

Кластер 2 (бирюзовые) — *«Группа низкой академической активности»*: студенты с минимальными временными затратами на учёбу и соответственно низкими экзаменационными результатами при вариативном уровне ментального благополучия.

Кластер 3 (фиалетовые) — «Сбалансированная высокоэффективная группа»: студенты, успешно совмещающие интенсивную учебную деятельность с высокими академическими результатами и сохранением психологического благополучия.




Рис 1. Интерфейс обрезки датасета по выбранным признакам.




Рис 12. Кластеризация обработанной базы данных, обрезанной до 3-х оптимальных признаков, выбранных алгоритмом СПА

6 Рекомендации пользователю

6.1 Установка и запуск

Python 3.11+

Установка зависимостей:

```
pip install pandas numpy matplotlib scikit-learn
```

Загрузка и запуск:

```
git clone
```

```
    ↪ https://github.com/MansurYa/4-sem-labs-for-algorithms-and-data-structures.git
```

```
cd 4-sem-labs-for-algorithms-and-data-structures/Lab5
```

```
python clustering_gui.py
```

6.2 Использование программы

После запуска откроется окно с панелями: управление слева, визуализация в центре, статистика справа (3 вкладки).

6.2.1 Этап 1: Подготовка данных

1. **“Загрузить данные”** — автоматически загружается `student_habits_performance.csv`
2. **“Предобработать”** — нормализация числовых и кодирование категориальных признаков

6.2.2 Этап 2: Анализ признаков

1. Установите **“Признаков для СПА”**: 3 (из 15 доступных)
2. **“Запустить СПА”** — алгоритм оценивает информативность каждого признака
3. **“Применить выбор признаков”** — в диалоге выберите рекомендованные СПА признаки (отмечены ☐)

6.2.3 Этап 3: Кластеризация

1. **Метод кластеризации:** односвязывающий (для задания) или K-Means (быстрее)
2. **Количество кластеров (K):** 3-5 для интерпретируемости результатов
3. **Метрика расстояния:** Чебышева (для односвязывающего по заданию)
4. **“Кластеризовать”** — выполнение алгоритма
5. **“Выбрать признаки для визуализации”** — выберите 3 признака для осей X, Y, Z

6.2.4 Этап 4: Анализ результатов

1. **“Анализ K-анонимности”** — оценка приватности данных
2. **“Анонимизировать и сравнить”** — сравнение качества кластеризации на разных этапах

6.3 Интерпретация результатов

- **3D график:** Точки окрашены по кластерам, можно поворачивать мышью
- **Вкладка “Общая статистика”:** размеры кластеров, индекс Фоулкса-Мэллова при сравнении
- **Вкладка “Результаты СПА”:** рекомендованные признаки с оценкой качества
- **Вкладка “Состояние данных”:** информация о каждом этапе обработки

7 Проведение эксперимента

7.1 Методология исследования

Исследование выполнено согласно техническому заданию в 4 этапа с количественной оценкой влияния трансформаций данных на качество кластеризации.

Экспериментальная схема:

1. **Базовая кластеризация:** односвязывающий метод на всех 16 признаках
2. **Выбор признаков и кластеризация:** СПА-анализ → отбор 3 признаков → повторная кластеризация
3. **Анонимизация и сравнение:** обезличивание → кластеризация → расчет FM-индексов
4. **Дополнительные эксперименты:** влияние K, контрольный метод K-means

Параметры алгоритмов:

- Односвязывающий метод: метрика Чебышева, $K = 3$ и 50
- СПА: выбор 3 из 16 признаков, метрика качества - силуэтный коэффициент
- Анонимизация: уровень moderate, целевая K-анонимность ≥ 2
- K-means (контроль): $K = 3$, евклидова метрика

Схема сравнений: Индекс Фоулкса-Мэллова требует две кластеризации. Кластеризация после предобработки принята за базовую. Выполнены три сравнения:

- Preprocessing vs Features: влияние отбора признаков
- Preprocessing vs Anonymized: влияние анонимизации
- Features vs Anonymized: комбинированное влияние

7.2 Результаты тестирования

7.2.1 Выбор информативных признаков

СПА-анализ выполнен для отбора 3 наиболее информативных признаков из 16.

Результаты СПА:

- Качество выбора: 0.363957
- Выбранные признаки:
 1. `social_media_hours` - время в социальных сетях
 2. `exam_score` - результат экзамена
 3. `sleep_hours` - продолжительность сна




Рис 13. Интерфейс выбора признаков СПА

7.2.2 Результаты кластеризации

Таблица 1. Сводные результаты экспериментов

Table 5: Сводные результаты экспериментов

№	Метод	К	Признаки	Распределение по кластерам	Примечания
1	Односвязывающий	3	Все 16	[1, 1, 998]	99.8% в одном кластере
2	Односвязывающий	3	СПА 3	[1, 1, 998]	Идентично эксп. 1
3	Односвязывающий	50	Все 16	[948, 46×1, 3×2]	94.8% в одном кластере
4	K-means	3	Все 16	[356, 346, 298]	Сбалансированные кластеры

Визуализация кластеризации K=3:

Кластеризация (K=3)




Рис 14. Односвязывающий метод: один доминирующий кластер (желтый) содержит 998 объектов

Кластеризация (K=3)




Рис 15. Проекция на выбранные СПА признаки

Кластеризация (K=3)




Рис 16. Кластеризация на наборе данных из 3-х столбцов, выбранных с помощью СПА

Визуализация кластеризации K=50:

Кластеризация (K=50)




Рис 17. 46 одиночных кластеров на периферии, 948 объектов в центральном кластере

Кластеризация (K=50)




Рис 18. Кластеризация на наборе данных из 3-х столбцов, выбранных с помощью СПА

Кластеризация (K=3)




Рис 19. K-means: три различных кластера с равномерным распределением

7.2.3 Результаты сравнения методов

Таблица 2. Индексы Фоулкса-Мэллова

Table 6: Индексы Фоулкса-Мэллова

Сравнение		K=3	K=50	Интерпретация
Preprocessing Features	vs	0.9980	0.9500	Минимальные изменения
Preprocessing Anonymized	vs	0.5831	0.4312	Существенные изменения
Features Anonymized	vs	0.5831	0.4312	Идентично предыдущей строке




Рис 20. Интерфейс выбора признаков СПА

К-анонимность: Достигнутое значение = 2 (минимально допустимый уровень защиты)

7.2.4 Количественные характеристики

Энтропия распределения кластеров:

Статистика K-means:

- Внутрикластерная сумма квадратов: 9443.50
- Центроиды кластеров:
 - Кластер 0: [-0.239, 0.442, 0.005...]
 - Кластер 1: [-0.019, -0.960, 0.146...]
 - Кластер 2: [0.308, 0.587, -0.176...]

7.3 Анализ результатов

7.3.1 Эффект цепочки в односвязывающем методе

Односвязывающий метод демонстрирует **катастрофическую неэффективность** на данном датасете:

- При $K=3$: 99.8% объектов в одном кластере
- При $K=50$: 94.8% объектов в одном кластере

Причина: Эффект цепочки - последовательное объединение объектов через локальные минимумы расстояний. В данных без естественных границ между группами метод объединяет почти все объекты в один массивный кластер.

Устойчивость эффекта:

- Смена метрики (Чебышева $\rightarrow$ евклидова): результат не изменился
- Сокращение признаков ($16 \rightarrow 3$): $FM = 0.9980$, практически идентичные результаты
- Увеличение K ($3 \rightarrow 50$): лишь “откалывает” периферийные объекты

7.3.2 Влияние отбора признаков

СПА выбрал разумную комбинацию признаков:

- Поведенческий (social_media_hours)
- Результативный (exam_score)
- Биологический (sleep_hours)

Качество выбора 0.364 указывает на умеренную информативность. Однако это не помогло улучшить кластеризацию односвязывающим методом ($FM = 0.9980$).

Вывод: При доминировании эффекта цепочки даже оптимальный выбор признаков не улучшает результат.

7.3.3 Влияние анонимизации

Анонимизация - **единственный фактор**, существенно изменивший структуру кластеров:

- При $K=3$: FM снизился до 0.5831 (41.7% изменений)
- При $K=50$: FM снизился до 0.4312 (56.9% изменений)

Механизм влияния: Генерализация и удаление редких комбинаций изменяют локальную структуру данных, частично разрушая цепочки минимальных расстояний.

7.3.4 Сравнение с K-means

K-means на тех же данных дает **принципиально иные результаты**:

- Сбалансированное распределение: [356, 346, 298]
- Визуально различимые кластеры

Причина успеха: K-means оптимизирует глобальный критерий (сумму квадратов расстояний до центроидов), игнорируя локальные цепочки.

8 Выводы

Эксперименты выявили фундаментальную неприменимость односвязывающего метода к данным без естественных кластерных границ: эффект цепочки привел к концентрации 99.8% объектов в одном кластере. Алгоритм СПА успешно выбрал информативные признаки (качество 0.364), однако это не компенсировало ограничения метода кластеризации (индекс Фоулкса-Мэллова 0.998). Анонимизация существенно изменила структуру данных (FM снизился до 0.583). Метрика Чебышева не повлияла на проявление эффекта цепочки. Сравнение с K-means подтвердило критичность выбора метода: на идентичных данных получены принципиально разные результаты.

9 Полезные ссылки

- Репозиторий с лабораторными работами за 4-й семестр
- Репозиторий с кодом лабораторной работы
- Набор данных “Student Habits vs Academic Performance”